المدرسة العليا للتكنولوجيا - كلميم

ⵜⴰⵙⴷⴰⵡⵉⵜ ⵜⴰⵏⴰⵎⵓⵔⵜ ⵏ ⵜⵓⵙⵙⵏⴰⵡⵉⵜ - ⴾⵍⵎⵉⵎ

ÉCOLE SUPÉRIEURE DE TECHNOLOGIE - GUELMIM

جامعة ابن زهر أكادير

UNIVERSITÉ IBN ZOHR - AGADIR

Rapport de mini projet :

Système intelligent de prédiction du prix des voitures

Réalise par :

Aya maaiguar

Salma zartouni

En cadre par:

M.Tarek Ait Baha

2025/2026

Table des matières

Système intelligent de prédiction du prix des voitures 1

1. Introduction 3

2. Objectifs du projet 3

3. Description du dataset 3

- *Variables principales :* 3
- *Problèmes identifiés :* 4

4. Prétraitement des données 4

- *Nettoyage* 4
- *Transformation* 4
- *Encodage* 5
- *Normalisation* 5

5. Modélisation supervisée 5

- *Modèle utilisé : Random Forest Regressor* 5
- *Entraînement* 5
- *Évaluation* 5

6. Modélisation non supervisée 6

- *Méthode utilisée : KMeans* 6
- *Objectif :* 6
- *Résultat :* 6

7. Visualisation des données 6

8. Dashboard interactif 7

- *Fonctionnalités :* 7
- *Avantage :* 7

9. Résultats obtenus 7

10. Limites du projet 7

12. Conclusion 8

1. Introduction

Avec la croissance du marché des voitures d'occasion, il devient difficile pour les acheteurs et vendeurs d'estimer correctement la valeur d'un véhicule. Plusieurs facteurs influencent le prix d'une voiture, tels que l'année de fabrication, le kilométrage, le type de carburant ou encore les caractéristiques techniques.

Dans ce contexte, l'utilisation du Machine Learning permet de développer des modèles capables de prédire automatiquement le prix des voitures à partir de leurs caractéristiques.

Ce projet a pour objectif de concevoir un système intelligent complet permettant :

- *La prédiction du prix des voitures*
- *L'analyse des données*
- *La visualisation interactive*
- *L'exploration des clusters de véhicules similaires*

2. Objectifs du projet

Les principaux objectifs de ce projet sont :

- *Développer un modèle de Machine Learning pour prédire le prix des voitures*
- *Appliquer une méthode de clustering pour analyser les données*
- *Concevoir un dashboard interactif pour visualiser les résultats*
- *Permettre à un utilisateur de faire des prédictions facilement*

3. Description du dataset

Le dataset utilisé provient de la plateforme Kaggle et s'intitule ***Car details v3.csv****.*

Il contient plusieurs milliers d'observations représentant différentes voitures avec leurs caractéristiques.

➢ *Variables principales :*

- ***name*** *: nom du véhicule*

- ***year*** *: année de fabrication*
- ***selling_price*** *: prix de vente*
- ***km_driven*** *: kilométrage parcouru*
- ***fuel*** *: type de carburant (Diesel, Petrol, etc.)*
- ***transmission*** *: type de transmission*
- ***engine*** *: puissance moteur (CC)*
- ***mileage*** *: consommation*
- ***max_power*** *: puissance maximale*

➢ *Problèmes identifiés :*

- *Présence de valeurs manquantes*
- *Colonnes numériques stockées sous forme de texte*
- *Variables catégorielles à encoder*

4. Prétraitement des données

Avant d'entraîner les modèles, plusieurs étapes de préparation ont été nécessaires.

➢ *Nettoyage*

- *Suppression des valeurs manquantes avec dropna()*
- *Suppression des valeurs incohérentes*

➢ *Transformation*

Certaines colonnes contiennent des unités :

- *mileage → suppression de "kmpl"*
- *engine → suppression de "CC"*
- *max_power → suppression de "bhp"*

Puis conversion en valeurs numériques :

```
df["engine"] = df["engine"].str.replace(" CC","").astype(float)
```

➢ *Encodage*

Les variables catégorielles ont été transformées en variables numériques avec :

pd.get_dummies(df)

➢ *Normalisation*

Pour le clustering, les données ont été normalisées avec :

StandardScaler()

5. Modélisation supervisée

➢ *Modèle utilisé : Random Forest Regressor*

Le modèle Random Forest a été choisi car :

- *Il est robuste face au bruit*
- *Il gère bien les relations non linéaires*
- *Il donne de bonnes performances sans beaucoup de réglages*

➢ *Entraînement*

Le dataset a été divisé en :

- *80% pour l'entraînement*
- *20% pour le test*

➢ *Évaluation*

Les métriques utilisées sont :

- *MAE (erreur absolue moyenne)*
- *MSE (erreur quadratique moyenne)*
- *R^2 (coefficient de détermination)*

➢ *Résultats :*

Modèle	*MAE*	*MSE*	*R^2*
Random Forest	*0.98*	*2.34*	*0.93*

Le modèle donne une très bonne précision avec un R^2 proche de 1.

6. Modélisation non supervisée

- *Méthode utilisée : KMeans*

L'algorithme KMeans a été utilisé pour regrouper les voitures en clusters similaires.

- *Objectif :*

- *Identifier des groupes de voitures similaires*
- *Comprendre la structure des données*

- *Résultat :*

*Les voitures ont été regroupées en **4 clusters** :*

- *Cluster 0 : voitures anciennes*
- *Cluster 1 : voitures moyennes*
- *Cluster 2 : voitures haut de gamme*
- *Cluster 3 : voitures économiques*

7. Visualisation des données

Plusieurs visualisations ont été réalisées :

- *Histogramme des prix*
- *Scatter plot (année vs prix)*
- *Graphique des clusters*
- *Carte interactive des voitures*

Ces visualisations permettent de mieux comprendre les données et les résultats du modèle.

8. Dashboard interactif

Une application a été développée avec Streamlit.

- *Fonctionnalités :*

- *Visualisation des données*
- *Prédiction du prix*
- *Clustering*
- *Recherche voiture*
- *Filtres avancés (prix, année, carburant)*
- *Carte interactive*

- *Avantage :*

L'utilisateur peut interagir avec les données sans connaissances techniques.

9. Résultats obtenus

- *Modèle de prédiction performant*
- *Clustering efficace*
- *Dashboard fonctionnel et interactif*
- *Visualisations claires*

Le système est utilisable dans un contexte réel.

10. Limites du projet

Malgré les bons résultats, certaines limites existent :

- *Données géographiques simulées*
- *Dataset limité*
- *Modèle non optimisé à 100%*
- *Certaines variables importantes absentes*

12. Conclusion

Ce projet a permis de développer un système intelligent complet combinant :

- *Machine Learning*
- *Data Analysis*
- *Visualisation*
- *Interface interactive*

Il constitue une solution efficace pour la prédiction du prix des voitures et peut être amélioré pour des applications réelles.